

ZIGURAT Institute of Technology

IL3-Universitat de Barcelona

**MAIC 1125 - Máster Internacional en Inteligencia Artificial para
Arquitectura y Construcción**

BLOQUE 2 | Áreas clave de la IA aplicadas al sector AECO

M4 | Programación e Inteligencia Artificial para el sector AECO

TEMA 3: Visión Computacional

M4T2/ Tarea

Martin Lesch

Adriana Zárate

08 de marzo del 2026, Buenos Aires / Asunción

**Prototipo AECO CV +
repositorio rep**

AUDITORÍA AUTOMATIZADA DE ACTIVOS EN OBRA MEDIANTE YOLOv8

Problema AECO

En la gestión de proyectos de construcción, los costos de alquiler de maquinaria representan una de las partidas más variables y difíciles de auditar.

El Problema: Existe una discrepancia constante entre las horas de trabajo reportadas manualmente y el uso real de las excavadoras (costo variable), así como una permanencia excesiva de torregrúas (costo fijo) fuera de sus etapas críticas de estructura.

Criterio de Éxito: Implementar un sistema de registro automático de presencia para contrastar:

Torregrúa: Días de permanencia real vs. Plazos de contrato.

Excavadora: Horas de actividad detectada vs. Partes de trabajo manuales.

EL DESAFÍO OPERATIVO SOBRECOSTOS INVISIBLES

La gestión tradicional de maquinaria pesada carece de herramientas de auditoría fiables, creando una “caja negra” financiera en el sitio de construcción.



Auditoría Imposible

Dificultad extrema para verificar los tiempos reales de actividad de torregrúas y horas efectivas de excavadoras versus tiempos muertos.



Dependencia Manual

Partes de trabajo manuales con alto margen de error humano, ilegibilidad y falta de trazabilidad digital inmediata.



Discrepancia en Facturación

Sin un registro automático imparcial, es imposible contrastar las facturas de alquiler con el uso real de los activos.



IMPACTO FINANCIERO DIRECTO

25%

De sobrecosto estimado en alquiler


**Promedio en obras de gran escala por falta de control de tiempos inactivos.*

/ PUNTOS DE DOLOR CRÍTICOS

- Datos dispersos
- Falta de visibilidad
- Procesos reactivos
- Disputas legales

TECNOLOGÍA APLICADA

Computer vision con YOLOv8



Entrenamiento Google Colab

Hiperparámetros de Entrenamiento:

Epochs: 30
Batch Size: 16
Image Size (imgsz): 640 px
Optimizer: Auto (SGD/AdamW)

Entorno de Ejecución:

Librería Principal: ultralytics v8.4.21
Hardware: Google Colab GNT
(Tesla T4 GPU)
Python: 3.10+

DEL PARTE MANUAL, A LA EVIDENCIA VISUAL OBJETIVA DETECCIÓN INTELIGENTE

Implementamos algoritmos de visión artificial de última generación (YOLOv8) para transformar flujos de video estándar en datos estructurados.

El sistema identifica y clasifica maquinaria pesada generando el comportamiento operativo en ora sin intervención humana.



¿POR QUÉ ESTA ARQUITECTURA?

Elegimos la versión Small por su agilidad. Procesa imágenes en ~70ms, permitiendo un monitoreo fluido sin necesidad de servidores masivos.

EL DATASET:

Curado en Roboflow para entrenar al modelo en condiciones reales: polvo, oclusiones y ángulos de cámara complejos.

MOTOR DE INFERENCIA

YOLOv8s

Seleccionado por su equilibrio crítico entre **velocidad** (tiempo real) y precisión en detalles finos.

- ✓ Reconoce celosías (Grúas)
- ✓ Modelo "Small" ligero


PIPELINE DE ENTRENAMIENTO

Google Colab & Roboflow

- Dataset curado en Roboflow
- 30 Épocas de entrenamiento
- Hardware: GPU Tesla T4

CLASES Y ETIQUETAS

Roboflow & SAM



Dataset

Gestionado en Roboflow con un split de 80% Train / 20% Valid

Enlace:
https://universe.roboflow.com/martins-workspace-7mzhv/maic_m4t3_tarea
(Versión 7)

IMÁGENES Y ETIQUETADO ROBOFLOW


Se eligieron 126 imágenes extraídas de Unsplash, sitio donde se almacenan numerosas imágenes libres de derechos.

En las imágenes aparecen sitios de construcción con maquinarias. Las mismas fueron etiquetadas por 2 clases diferentes.

El proceso de etiquetado si bien se realizó mayormente manual, tuvo utilización de SAM. Sin embargo el mismo fue utilizado más hacia el final del entrenamiento ya que al principio detectaba gran cantidad de falsos negativos.

CLASES

1. Torregrúa: Activo crítico de coste fijo diario.
2. Excavadora: Activo de coste variable por hora de operación.



RESULTADO DE LA EJECUCIÓN



Rendimiento y métricas reales

ANÁLISIS DE MÉTRICAS RESULTADOS

Basado en las curvas de entrenamiento ejecutadas:

Rendimiento General: El modelo alcanzó un mAP₅₀ cercano a 0.5 (50%) y un mAP₅₀₋₉₅ de ~0.28. Aunque son valores iniciales para 30 épocas, la tendencia es claramente ascendente.

Precisión y Recall: Se observa un Precision (B) de aproximadamente 0.8 (80%) al final del entrenamiento, lo que indica que cuando el modelo detecta una máquina, suele estar en lo correcto. El Recall es más bajo (~0.45), sugiriendo que aún omite algunas máquinas en entornos muy congestionados.



LIMITACIONES

Evaluación crítica del desempeño del modelo en condiciones adversas

Limitaciones Técnicas

Desafíos del Entorno

- Clima Adverso**

Lluvia intensa o niebla densa pueden reducir la confianza de detección < 60%.
- Oclusiones**

Obstáculos temporales en obra que bloquean la línea de visión de la cámara.
- Iluminación**

Falsos negativos en operaciones nocturnas con iluminación deficiente.

FALSOS NEGATIVOS

TORREGRÚAS ADICIONALES EN EL SECTOR CENTRAL DE LA OBRA:

Para este tipo de escenas, el auditor debe realizar una validación manual. Un fallo aquí resultaría en una subestimación del 66% de la capacidad instalada en obra, afectando gravemente el control de costos fijos por alquiler de maquinaria.

DETECCIÓN MÚLTIPLE DE ACTIVOS EN CONDICIONES DE LUZ DE ATARDECER/CONTRALUZ:

Este caso demuestra que el modelo YOLOv8s es sensible a las condiciones de iluminación extrema (Golden Hour). Para mitigar esto, se recomienda aplicar Aumentos de Datos (Augmentations) de tipo 'Blur' o 'Brightness contrast' durante el entrenamiento, y ajustar el parámetro IOU (Intersection over Union) en la inferencia para forzar la eliminación de cuadros duplicados en un mismo activo.

FALSO NEGATIVO POR ESCALA Y FALTA DE CONTRASTE:

Este error subraya la importancia de incluir imágenes en escala de grises o con variaciones de saturación durante el entrenamiento (Data Augmentation). Un FN en este escenario implicaría que el sistema no registraría ninguna actividad en una zona de trabajo crítica, generando un vacío en la auditoría de horas-máquina.

FALSOS POSITIVOS

FALSO POSITIVO POR FRAGMENTACIÓN (DUPLICIDAD):

Este FP demuestra la necesidad de ajustar el parámetro de IOU (Intersection over Union) durante la inferencia para forzar al algoritmo de NMS a fusionar cuadros delimitadores que estén muy cercanos verticalmente sobre la misma clase. Un FP aquí duplicaría erróneamente el cobro diario por el mismo activo fijo.

FALSO POSITIVO POR CONFUSIÓN DE PATRÓN ESTRUCTURAL:

Este FP subraya la necesidad de un Humano en el Bucle para validar detecciones con confianza inferior a 0.50. Una alucinación aquí activaría un protocolo de cobro de alquiler por un activo inexistente, resultando en un sobre costo directo del 100% en la partida de grúas para esa jornada.

FALSO POSITIVO POR CONFUSIÓN DE CLASE SEMÁNTICA:

Este caso resalta el riesgo de contaminación de métricas de costo variable. Confundir un camión pluma con una excavadora inflaría artificialmente las horas de operación de movimiento de tierras. Se recomienda entrenar una clase adicional de 'Otros Equipos' para ayudar al modelo a aprender por contraste qué elementos NO pertenecen a las categorías críticas de Torregrúa y Excavadora.

FALSOS NEGATIVOS

OMISIÓN DE DETECCIÓN

CAUSA PRINCIPAL

Contraluz Extremo (Siluetas)

Escenas a contraluz generan siluetas oscuras con baja textura interna. El modelo pierde los rasgos distintivos de celosía en torregrúas y contornos de excavadoras.

IMPACTO OPERATIVO

Pérdida de trazabilidad en ciertas franjas horarias (amanecer/atardecer). Puede resultar en un sub-reporte de horas de maquinaria activa.

FALSOS POSITIVOS

DETECCIÓN ESPURIA

CAUSA PRINCIPAL

Patrones Metálicos en Fachadas

Estructuras repetitivas como andamios, celosías de fachada o paneles metálicos son confundidos con la estructura de una torregrúa por similitud geométrica.

IMPACTO OPERATIVO

Generación de alertas incorrectas que inflan el inventario percibido. Requiere filtrado manual (Humano en el Bucle) para no afectar la facturación.

GOBERNANZA Y ÉTICA

Estrategia de supervisión humana y privacidad por diseño

EL FACTOR HUMANO EN LA IA GOBERNANZA Y ÉTICA

En este proyecto, la tecnología respalda el criterio profesional es decir, no reemplaza el factor humano:

PRIVACIDAD POR DISEÑO

El modelo ha sido entrenado y configurado para detectar elementos, no personas. El sistema trabaja centrándose exclusivamente en la identificación de maquinaria pesada para fines logísticos.

HUMANO EN EL BUCLE (HITL)

Entendemos que una tasa de precisión del 80% es buena, pero no infalible para decisiones financieras. Por ello, establecemos que cualquier detección con una confianza inferior al 50% o que presente discrepancias mayores al 20% frente a los partes de obra, debe ser validada manualmente por un auditor antes de procesar cualquier pago o reporte oficial.

TRANSPARENCIA OPERATIVA

La IA se utiliza como una "capa de verdad" objetiva para reducir la asimetría de información entre contratistas y gerencia. No buscamos el control punitivo del personal, sino la optimización de recursos y la transparencia en el uso de activos alquilados, garantizando que cada hora facturada corresponda a una hora de presencia real en terreno.

**PRIVACIDAD DE OPERARIOS**

**Protección de Datos Personales**

El sistema está diseñado para auditar máquinas, no personas.

- ✓ **Mínima Captura:** Solo se procesan frames donde hay maquinaria.
- ✓ **Clases Restringidas:** El modelo solo reconoce 'Torregrúa' y 'Excavadora'.
- ✓ **Anonimización:** No hay reconocimiento facial ni seguimiento de EPIS.

**MAQUINARIA**
DETECTADO

**OPERARIO**
IGNORADO

CONCLUSIONES

Tenemos un prototipo funcional que elimina la subjetividad en el control de obra.

"La automatización del registro visual es una mejora tecnológica: pasar de una gestión basada en la buena voluntad a una basada en datos. Al cruzar los partes de trabajo manuales con las detecciones reales del modelo eliminamos las zonas grises en la facturación de maquinaria pesada. En el fondo, es dotar al proyecto de una transparencia técnica necesaria: dejamos atrás el reporte de palabra para gestionar la obra con evidencias físicas, procesadas con el rigor que hoy exige cualquier presupuesto de gran escala."

RENDIMIENTO VS. PRECISIÓN

Se valida que YOLOv8s es la arquitectura idónea para el entorno AECO. Su latencia de ~70ms permite un monitoreo fluido, superando a modelos de segmentación como SAM (con latencias de ~1.2s), los cuales quedan relegados a auditorías forenses o etiquetado de precisión.

GESTIÓN DE LA INCERTIDUMBRE (LIMITACIONES)

El modelo presenta "puntos ciegos" específicos en situaciones de contraluz extremo, baja saturación cromática y patrones mimetizados con fachadas (falsos positivos/negativos). Estas limitaciones técnicas se asumen no como fallos del sistema, sino como parámetros de diseño que definen el alcance de la herramienta.

ESTRATEGIA "HUMAN-IN-THE-LOOP"

Para blindar la fiabilidad financiera del proyecto, se establece que el modelo no actúe de forma autónoma. La estrategia operativa consiste en un filtrado por umbral de confianza, donde cualquier detección inferior al 70% o con discrepancias mayores al 15% frente a reportes manuales, requiere validación humana obligatoria.

IMPACTO EN LA TRANSPARENCIA

En última instancia, la automatización de la evidencia visual transforma la gestión de obra. Pasamos de un control basado en "partes de palabra" a un sistema de auditoría objetivo y verificable, eliminando la subjetividad en la facturación de maquinaria pesada y asegurando que cada dato se base en una evidencia física rigurosa.

